

图像分类卷积神经网络的搭建及训练

(基于 pytorch 框架)

学生：2113662 张丛

指导教师：王恺

课程：python 编程基础

目录

引言

相关工作

Pytorch 是什么

Pytorch 安装

Pycharm 安装

方法

神经网络结构

实验

网络结构的实现

神经网络搭建全过程

数据预处理

损失函数与反向传播

全部代码（附注释）

结论

优化

大作业心得

引言

Python 编程语言已经成为近几年最流行、最火爆的的编程语言，作为计网的一员，我也于 2022 年正式在王恺老师的课上学习 python。在课上我震惊于 python 语言的简洁、强大，对 python 语言也产生了浓厚的兴趣。在课程大作业方面，我选择的高难度的神经网络搭建，也是对自己的一项挑战。

相关工作：Pytorch 环境搭建

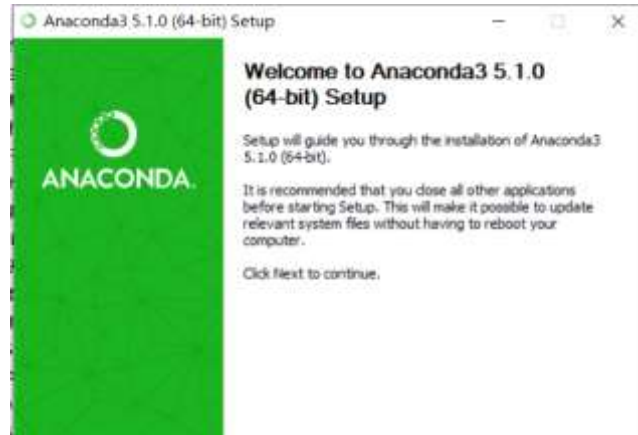
1.Pytorch 是什么？

他是一个基于Python的科学计算包，目标用户有两类

- 为了使用GPU来替代numpy
- 一个深度学习援救平台：提供最大的灵活性和速度

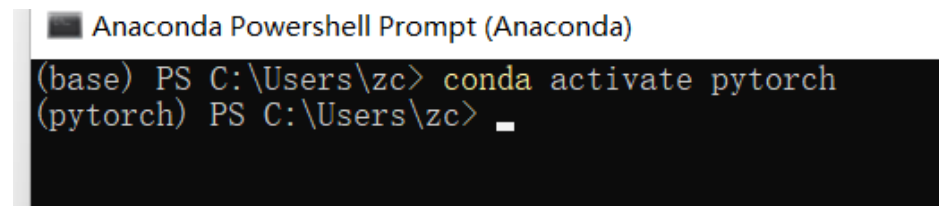
2.pytorch 安装

Anaconda 安装




创建虚拟房间

激活 pytorch 房间

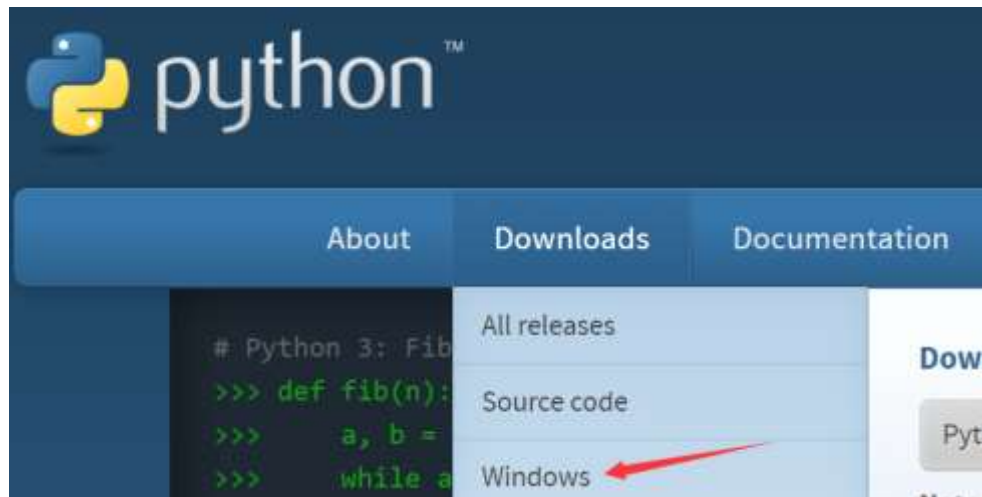


安装 pytorch



3.Pycharm 安装

配置 python



安装 pycharm



在 pycharm 中添加 pytorch 环境的解释器



方法

卷积神经网络(CNN):

CNN 用的是权值共享，即后一层不同神经的输入会共享相同的权值组，且后一层每个神经元的输入只受前一层部分神经元输出的影响。这样做的好处的避免纠缠不必要的细节，而是尽量抽象出整体特征，这点十分适用于图像识别。

神经网络框架：

1.卷积

卷积层是卷积神经网络的核心层，核心的处理方式就是卷积计算。卷积其实也就可以看成一个函数或者一种算法。这个函数则需要输入数据和卷积核，按照卷积要求进行计算。

卷积层其实是提取图像特征的过程。

2.激活

为了保证对数据非线性处理，也需要激活函数，也就是激活层的处理。其处理方式是，为卷积核的每个元素添加一个 bias(偏移值)，然后送入诸如 relu、leakyRelu、tanh 等非线性激活函数即可。

3.池化

池化(Pooling)又称下采样，可以进一步降低网络训练参数和模型过拟合的程度。

常用的池化处理有以下几种：

- 最大池化(Max Pooling)：选择 Pooling 窗口中的最大值作为采样值
- 均值池化(Mean Pooling)：将 Pooling 窗口中的所有值加起来取平均，使用平均值作为采样值
- 全局最大(或均值)池化：取整个特征图的最大值或均值

4.全连接层和输出层

这部分主要连接最后池化后的结果，将池化后的数据展平构成全连接层的输入。然后就是根据类别数构建的一个分类层，也就是输出层。

对于分类任务输出层则添加一个 sigmoid 层计算需要分类的图片各个类别的概率。对于训练任务，则使用损失函数开始反向传播更新模型中的卷积核。

实验

一.网络结构的实现：

卷积:二维卷积

```
nn.Conv2d(3, 48, kernel_size=11, stride=4, padding=2),
```

激活: inplace 为 True, 将会改变输入的数据

```
nn.ReLU(inplace=True),
```

池化: 最大池化 (二维)

```
nn.MaxPool2d(kernel_size=3, stride=2)
```

Flatten: 降维展平

```
nn.Flatten(),
```

Dropout: 减少过拟合

```
nn.Dropout(p=0.5),
```

Linear: 设置全连接层

```
nn.Linear(1024, 5),
```

向前传播: forward


```
def forward(self, x):
    x = self.model(x)
    return x
```

二.神经网络搭建全过程：

```
class alexnet(nn.Module):
    def __init__(self):
        super(alexnet, self).__init__()
        self.model = nn.Sequential(

            nn.Conv2d(3, 48, kernel_size=11, stride=4, padding=2), # input[3, 128, 128] output[48, 55, 55]

            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=3, stride=2), # output[48, 27, 27]
            nn.Conv2d(48, 128, kernel_size=5, padding=2), # output[128, 27, 27]

            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=3, stride=2), # output[128, 13, 13]
            nn.Conv2d(128, 192, kernel_size=3, padding=1), # output[192, 13, 13]

            nn.ReLU(inplace=True),
            nn.Conv2d(192, 192, kernel_size=3, padding=1), # output[192, 13, 13]

            nn.ReLU(inplace=True),
            nn.Conv2d(192, 128, kernel_size=3, padding=1), # output[128, 13, 13]

            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=3, stride=2), # output[128, 6, 6]
            nn.Flatten(),
            nn.Dropout(p=0.5),
            nn.Linear(512, 2048),
            nn.ReLU(inplace=True),
            nn.Dropout(p=0.5),
            nn.Linear(2048, 1024),
            nn.ReLU(inplace=True),

            nn.Dropout(p=0.5),
            nn.Linear(2048, 1024),
            nn.ReLU(inplace=True),
            nn.Linear(1024, 5),

        )

    def forward(self, x):
        x = self.model(x)
        return x
```

三.数据预处理:

```
data_transform = {  
    "train": transforms.Compose([transforms.RandomResizedCrop(120),  
                                transforms.RandomHorizontalFlip(),  
                                transforms.ToTensor(),  
                                transforms.Normalize([0.5, 0.5, 0.5], (0.5, 0.5, 0.5))]),  
    "val": transforms.Compose([transforms.Resize((120, 120)),  
                              transforms.ToTensor(),  
                              transforms.Normalize([0.5, 0.5, 0.5], (0.5, 0.5, 0.5))])}
```

torchvision.transforms 是 pytorch 中的图像预处理包，一般用 Compose 把多个图片变换步骤整合到一起。

(实际是个列表, 而这个列表里面的元素就是你想要执行的 transform 操作。

Compose()类会将 transforms 列表里面的 transform 操作进行遍历。)

运用的图形变换:

CenterCrop:在图形的中间区域进行裁剪

RandoHorizontalFlip:以 0.5 的概率水平翻转图像

Totensor:将 shape 为 (H,W,C) 的图像转为 shape 为 (C,H,W) 的 tensor。

(Tensor 即为描述网络输入、输出、参数的张量)

Normalize:进行标准化、归一化处理，把 0~255 的灰度值像素数据归一化为均值为 0.5、标准差为 0.5 的数据。

```
train_set = torchvision.datasets.ImageFolder(root="date\\train", transform=data_transform["train"])  
train_data = DataLoader(dataset=train_set, batch_size=128, shuffle=True, num_workers=0)  
test_set = torchvision.datasets.ImageFolder(root="date\\val", transform=data_transform["val"])  
test_data = DataLoader(dataset=test_set, batch_size=128, shuffle=True, num_workers=0)
```

DateLoader:指定数据集，且分批次按 Batch_size=128 读取，shuffle=True

则表示对数据随机读取

四.损失函数与反向传播：

(1)nn.CrossEntropyLoss(),交叉熵损失：

nn.Cross Entropy Loss的公式。

$$\text{Loss}(x, class) = -\log\left(\frac{e^{x[class]}}{\sum_i e^{x[i]}}\right) = -x[class] + \log\left(\sum_i e^{x[i]}\right)$$

例：一个三分类问题，有 person (0) ,cat (1) ,dog (2) 三个类

Output: [0.1,0.2,0.3]

Target:1

则,loss=-0.2+log(exp(0.1)+exp(0.2)+exp(0.3))=1.1019

(2)优化器：调用损失函数的 backward（反向传播），求出每个需要调节的参数对应的梯度。此时使用优化器利用这个梯度对参数进行调整，以达到降低整体误差的目的。

```
optimizer = optim.SGD(net.parameters(), 1e-2)
```

```
#择优化器算法，调用模型参数，学习率=0.001
```

```
optimizer.step()
```

```
#调整参数
```

全部代码(及部分注释):

```
import torch
import numpy as np
import torchvision
from torch.utils.data import DataLoader
from torchvision.datasets import mnist
from torch import nn
from torch.autograd import Variable
from torch import optim
from torchvision import transforms

# 定义神经网络
class CNN(nn.Module):
    def __init__(self):
        super(CNN, self).__init__()
#调用父类初始化函数

        self.model = nn.Sequential(
#将网络结构放在一个序列当中，可以方便 forward 函数的书写

            nn.Conv2d(3, 48, kernel_size=11, stride=4, padding=2),
#卷积层 input[3, 120, 120] output[48, 55, 55]
            nn.ReLU(inplace=True),
#激活层，非线性处理
            nn.MaxPool2d(kernel_size=3, stride=2),
#最大池化 output[48, 27, 27]

            nn.Conv2d(48, 128, kernel_size=5, padding=2),
# output[128, 27, 27]
            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=3, stride=2),
# output[128, 13, 13]

            nn.Conv2d(128, 192, kernel_size=3, padding=1),
# output[192, 13, 13]
            nn.ReLU(inplace=True),

            nn.Conv2d(192, 192, kernel_size=3, padding=1),
# output[192, 13, 13]
            nn.ReLU(inplace=True),
```

```

        nn.Conv2d(192, 128, kernel_size=3, padding=1),
# output[128, 13, 13]

        nn.ReLU(inplace=True),
        nn.MaxPool2d(kernel_size=3, stride=2),
# output[128, 6, 6]

        nn.Flatten(),
#降维展平
        nn.Dropout(p=0.5),
#防止模型过拟合
        nn.Linear(512, 2048),
#线性层
        nn.ReLU(inplace=True),
        nn.Dropout(p=0.5),
        nn.Linear(2048, 1024),
        nn.ReLU(inplace=True),
        nn.Linear(1024, 5),
    )
    def forward(self, x):
#前向传播
        x = self.model(x)
        return x

# 预处理
data_transform = {
    "train": transforms.Compose([transforms.CenterCrop(120),
                                transforms.RandomHorizontalFlip(),
                                transforms.ToTensor(),
                                transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))]),
    "val": transforms.Compose([transforms.CenterCrop(120),
                               transforms.RandomHorizontalFlip(),
                               transforms.ToTensor(),
                               transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))])}

train_set = torchvision.datasets.ImageFolder(root="date\\train",
transform=data_transform["train"])
#准备数据集
train_data = DataLoader(dataset=train_set, batch_size=128, shuffle=True, num_workers=0)
#加载数据集
test_set = torchvision.datasets.ImageFolder(root="date\\val", transform=data_transform["val"])
test_data = DataLoader(dataset=test_set, batch_size=128, shuffle=True, num_workers=0)
net = CNN()
criterion = nn.CrossEntropyLoss() # 使用交叉熵损失

```

```
optimizer = optim.SGD(net.parameters(), 1e-2) # 随机梯度下降, 学习率为 0.1
```

```
nums_epoch = 20
```

```
#训练轮数
```

```
device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")
```

```
#优先使用 GPU(如果有)
```

```
# 开始训练
```

```
for epoch in range(nums_epoch):
```

```
    print(epoch + 1)
```

```
    train_loss = 0
```

```
    train_acc = 0
```

```
    net = net.train()
```

```
    for img, label in train_data:
```

```
        img.to(device)
```

```
        label.to(device)
```

```
        img = Variable(img)
```

```
        label = Variable(label)
```

```
        out = net(img)
```

```
        loss = criterion(out, label)
```

```
        optimizer.zero_grad() # 每次将梯度重置为 0
```

```
        loss.backward() # 反向调整参数
```

```
        optimizer.step()
```

```
    # 记录误差
```

```
    train_loss += loss.item()
```

```
    # 计算分类的准确率
```

```
    pred = out.max(1) # 取评分最高的结果作为所分的类别
```

```
    num_correct = (pred == label).sum().item()
```

```
    acc = num_correct / img.shape[0]
```

```
    train_acc += acc
```

```
eval_loss = 0
```

```
eval_acc = 0
```

```
# 测试集不训练
```

```
for img, label in test_data:
```

```
    img.to(device)
```

```
    label.to(device)
```

```
    net.eval()
```

```
    img = Variable(img)
```


```
    label = Variable(label)
```


训练结果 2:

```
16
Epoch 17 Train Loss 1.1638498376495623 Train Accuracy 0.3761237256371776 Test Loss 1.5535986258559488 Test Accuracy 0.6295822163128567
17
Epoch 18 Train Loss 1.2816494832725348 Train Accuracy 0.3778919868627289 Test Loss 1.1932843733437476 Test Accuracy 0.5912522163128566
18
Epoch 19 Train Loss 1.6275493758343246 Train Accuracy 0.3723452638627385 Test Loss 1.2643741177436539 Test Accuracy 0.6113745453128569
19
Epoch 20 Train Loss 1.1735845295759894 Train Accuracy 0.3761253837462716 Test Loss 1.2973747658357558 Test Accuracy 0.6312433853126964

Process finished with exit code 0
```

测试集和训练集的损失与正确率的可视化:



由以上可得, 该模型的 loss 随训练轮数逐渐降低, accur 随训练轮数逐渐升高。

平均正确率达到 0.57 左右, 最高可达到 0.63

预测的结果较好

优化：

一.单张图片的预测：

```
torch.save(net.state_dict(), "net.pth")
```

此函数将训练好的模型参数保存到"net.pth"路径中，有此文件，我们可以不再经过训练直接预测图片的类别，以单张为例。

```
#数据处理
image_path = "valid/0/20170323093945725.jpg" # 将要预测的图片放到跟predict同一个文件夹下
trans = transforms.Compose([transforms.Resize((120, 120)),
                             transforms.ToTensor()])
image = Image.open(image_path)
image = image.convert("RGB")
image = trans(image)
image = torch.unsqueeze(image, dim=0)

classes = ["0", "1", "2", "3", "4"] #有五个类为0, 1, 2, 3, 4, 5

device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")#使用GPU

alexnet1 = net()
alexnet1.load_state_dict(torch.load("net.pth", map_location=device)) # train代码保存

outputs = alexnet1(image)#预测概率

ans = (outputs.argmax(1)).item()
print("预测结果：")
print(classes[ans]) # 输出的是那种即为预测结果
```

二．类别不平衡的分类问题

即某些类在样本中占比过大，某些类在样本中占比却过小，训练的模型可能会将数据都标注为占比大的样本。

解决方法：

1. 重采样：对少样本过采样，对多样本欠采样。

拿二元分类为例，如果训练集中阳性样本有1000个，阴性样本有10万个，两者比例为1: 100严重失衡。为了一些模型的性能考虑，我们需要进行一些处理使得两者的比例尽可能接近。

过采样：对少的一类进行重复选择，比如我们对1000个阳性样本进行有放回地抽样，抽5万次（当然其中有很多重复的样本），现在两类的比例就变成了1: 2，比较平衡。

欠采样：对多的一类进行少量随机选择，比如我们对10万个阴性样本进行随机选择，抽中2000个（当然原样本中很多样本未被选中），现在两类的比例就变成了1: 2，比较平衡。

2. 数据合成：若不想直接重复采样相同样本，一种解决方法是生成和少样本相似的“新”数据。
3. 重加权：重加权是对不同类别（甚至不同样本）分配不同权重。
4. 模型集成：融合多个训练好的模型，基于某种方式实现测试数据的多模型融合，这样来使最终的结果能够“取长补短”，融合各个模型的学习能力，提高最终模型的泛化能力

大作业心得：

因为之前并没有接触 Python，所以在这一学期的 Python 学习也算痛并快乐着。但看到大作业跑通的时刻，总感觉还是可喜可贺，即便需要优化的地方还有很多，即便正确率不是很高。

Python 确实是很强大的，就算只学了半学期的 Python，在运用上竟已经超过练习时长超过一年半的 C++。而且像数电课、概率论、汇编这些课程，还经常接触到 Python 来暴力运算，让我不得不感叹。

相信 Python 还会陪伴我的编程生涯。